Mg. Ing. Ezequiel Guinsburg

ezequiel.guinsburg@gmail.com

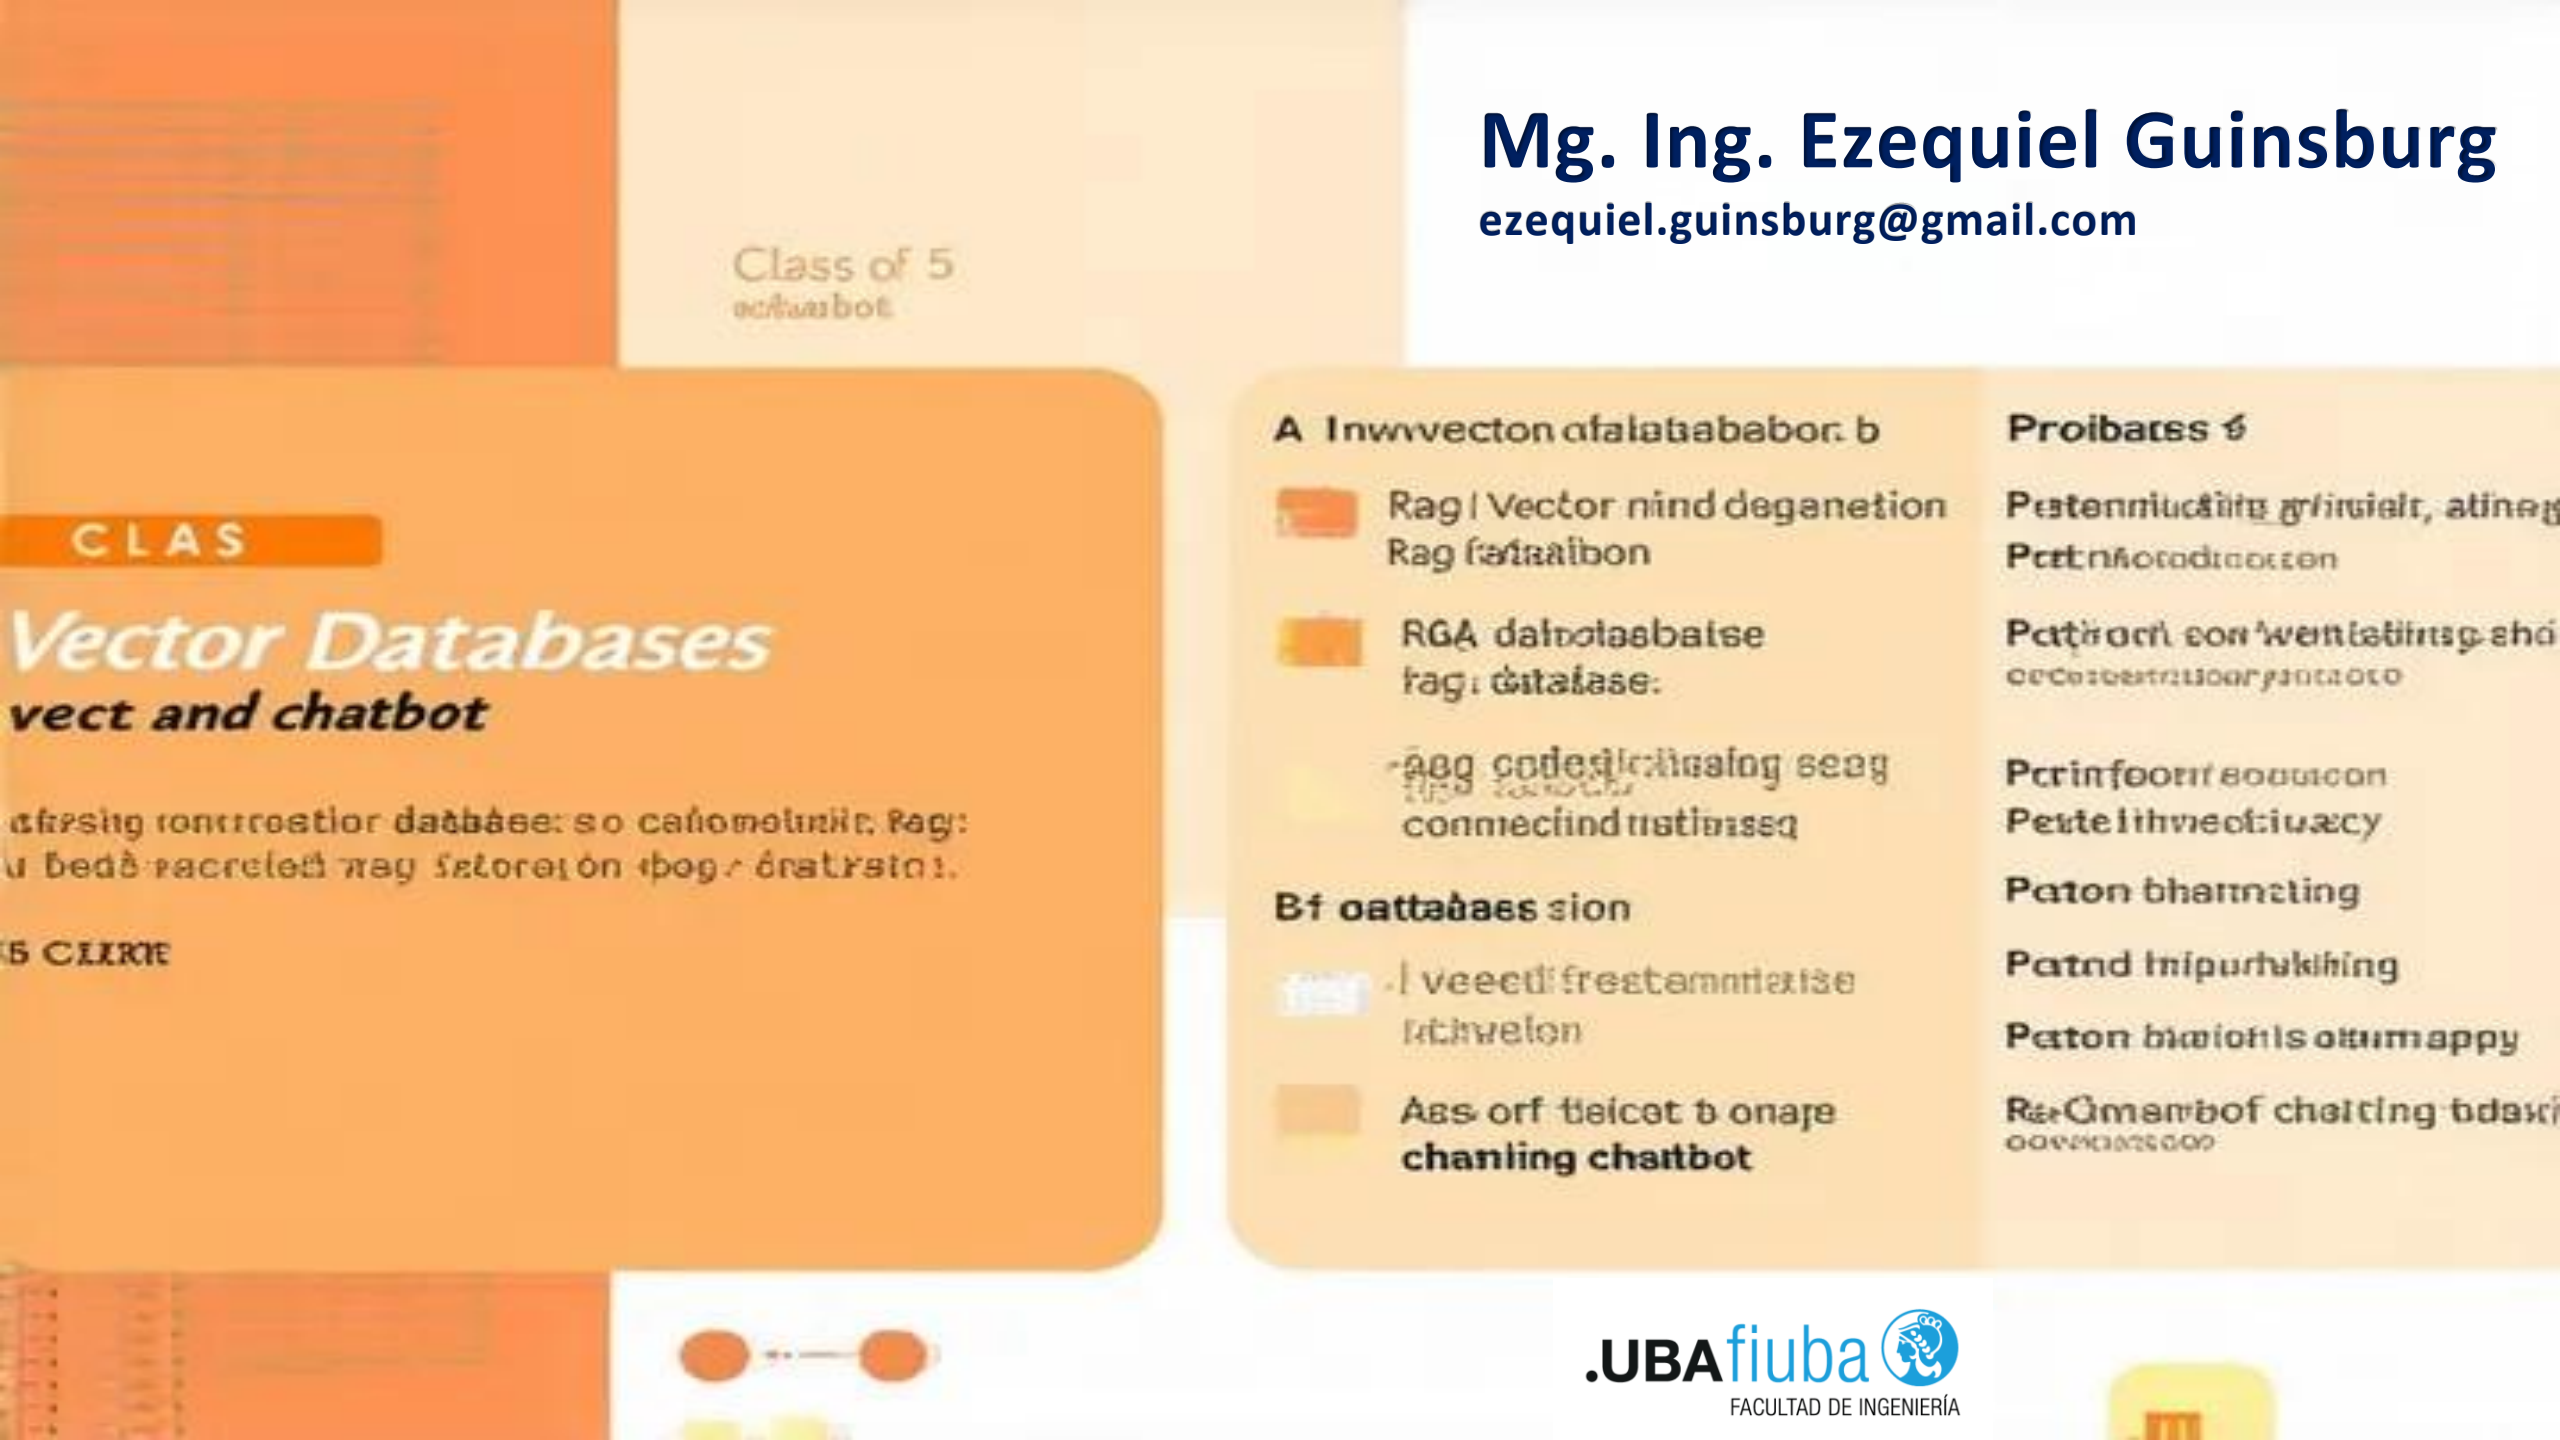

.UBAfiuba
FACULTAD DE INGENIERÍA

Universidad de Buenos Aires

Almacenamiento vectorial en RAG: multimodal y chatbots

- Bases de datos vectoriales (en contexto RAG)
- Retrieval Augmented Generation (RAG
- RAG Multimodal
- Chatbots

Mg. Ing. Ezequiel Guinsburg
ezequiel.guinsburg@gmail.com

PLN 2

Temas:

- Bases de datos vectoriales (en contexto RAG)
- Retrieval Augmented Generation (RAG)
- RAG Multimodal
- Chatbots

Referencias:

- Paper “IMAGEBIND: One Embedding Space To Bind Them All“
- Paper “Retrieval-Augmented Generation for Knowledge Intensive NLP Tasks”
- Paper FAISS (Billion-scale similarity search with GPUs)

Link REPO

Bases de datos vectoriales:

- Características

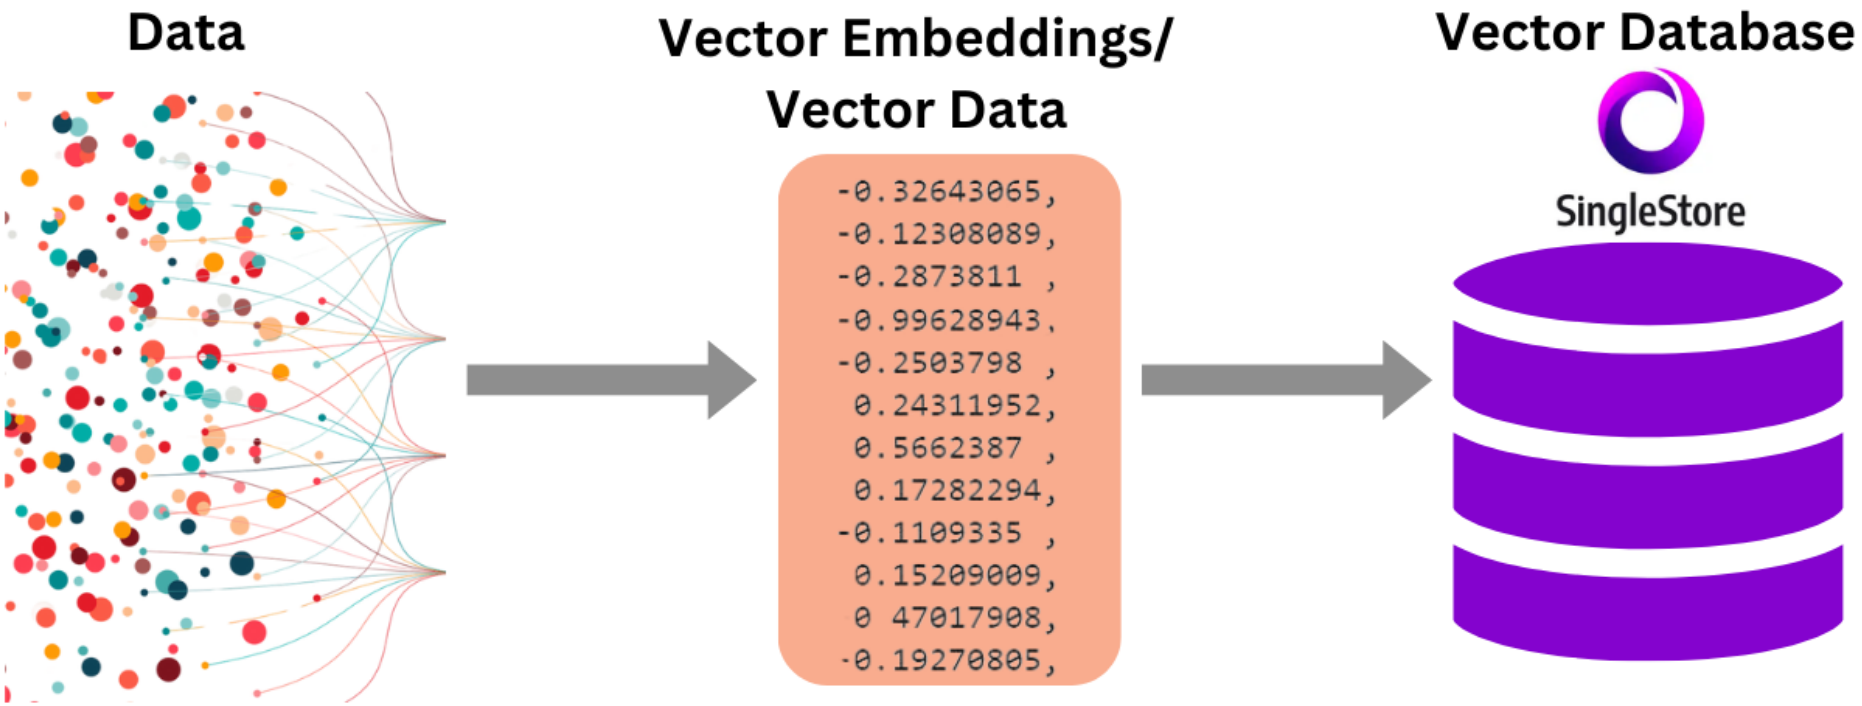

Bases de datos vectoriales:

- Búsqueda por similitud
  - Distancia de Hamming(A,B)=∑(Ai <> Bi)
  - L1(A,B)=i∑|Ai−Bi|

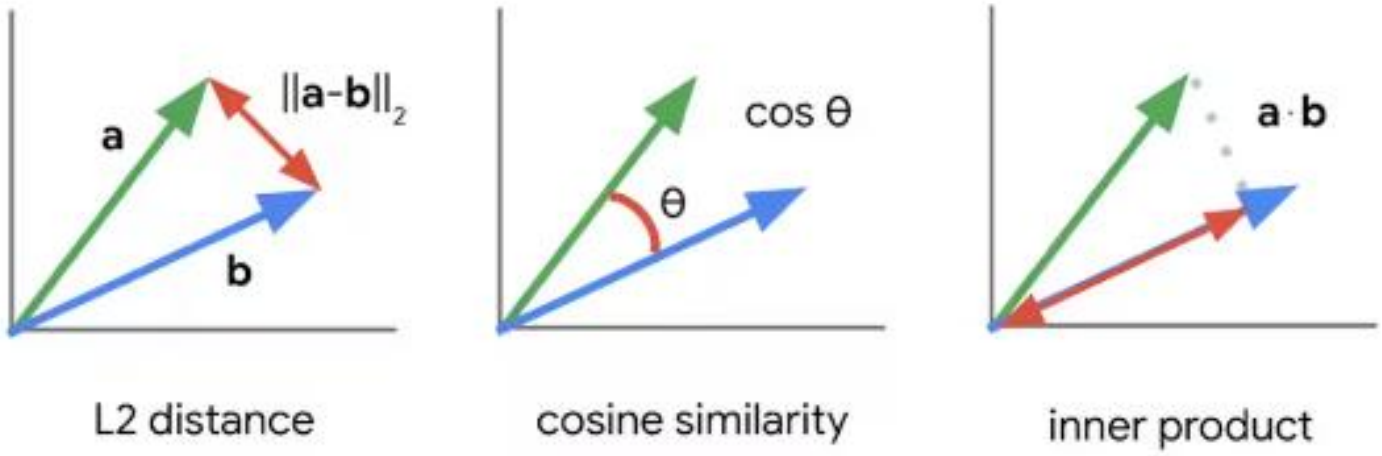

Bases de datos vectoriales:

- Algoritmos de ordenamiento para búsquedas eficientes:
  - k-dimensional tree
  - Locality Sensitive Hashing (LSH)
  - Faiss (Facebook AI Similarity Search) (link)

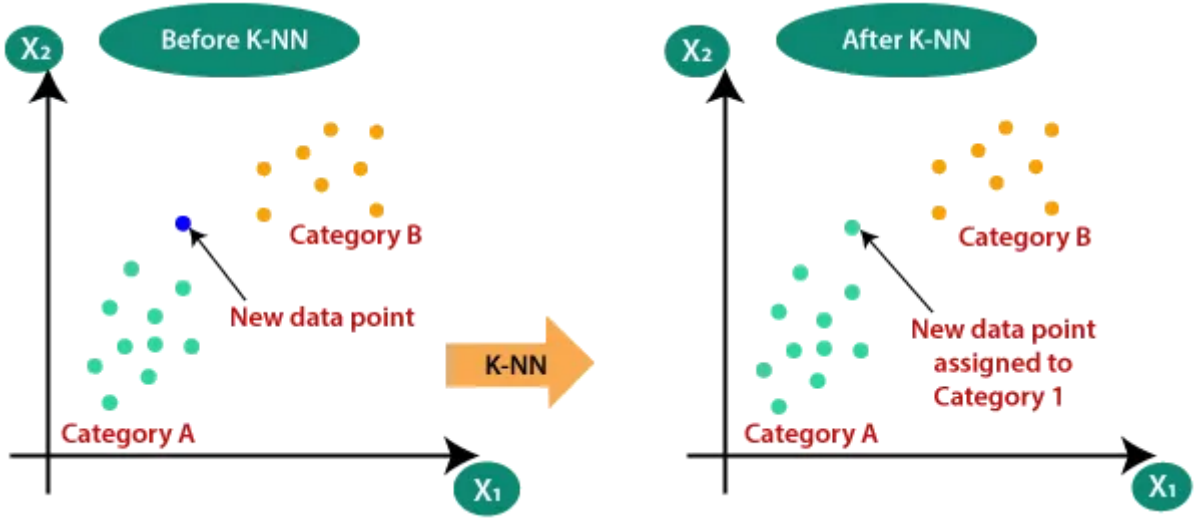

Source: Medium

Bases de datos vectoriales:

- Panorama

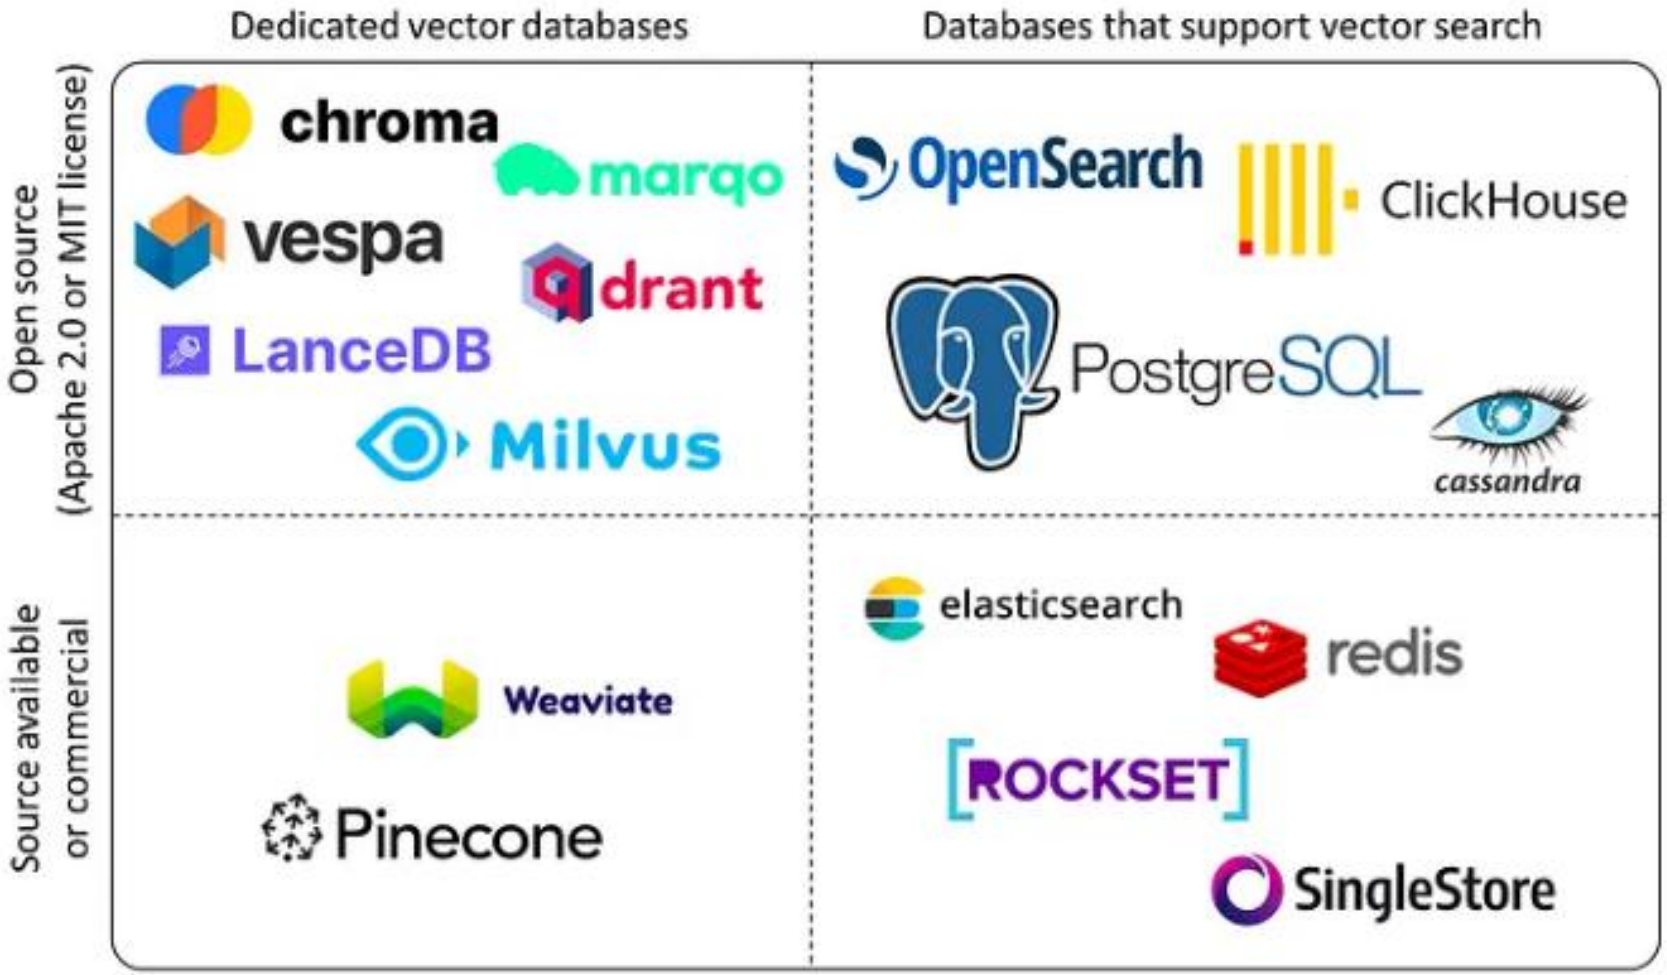

Bases de datos vectoriales:

- Ejemplo

https://docs.pinecone.io/guides/search/rerank-results

- Re-ranking: Técnica utilizada para mejorar los resultados de una búsqueda o recuperación de información. En lugar de depender únicamente de la primera búsqueda para proporcionar los resultados más relevantes, el re-ranking ajusta el orden de esos resultados con la ayuda de un modelo adicional que evalúa la relevancia semántica de los resultados con respecto a la consulta inicial.

Bases de datos vectoriales:

- Búsquedas Híbridas

https://docs.pinecone.io/guides/data/understanding-hybrid-search

https://github.com/pinecone-io/examples/blob/master/learn/search/hybrid-search/ecommerce-search/ecommerce-search.ipynb

Retrieval Augmented Generation (RAG):

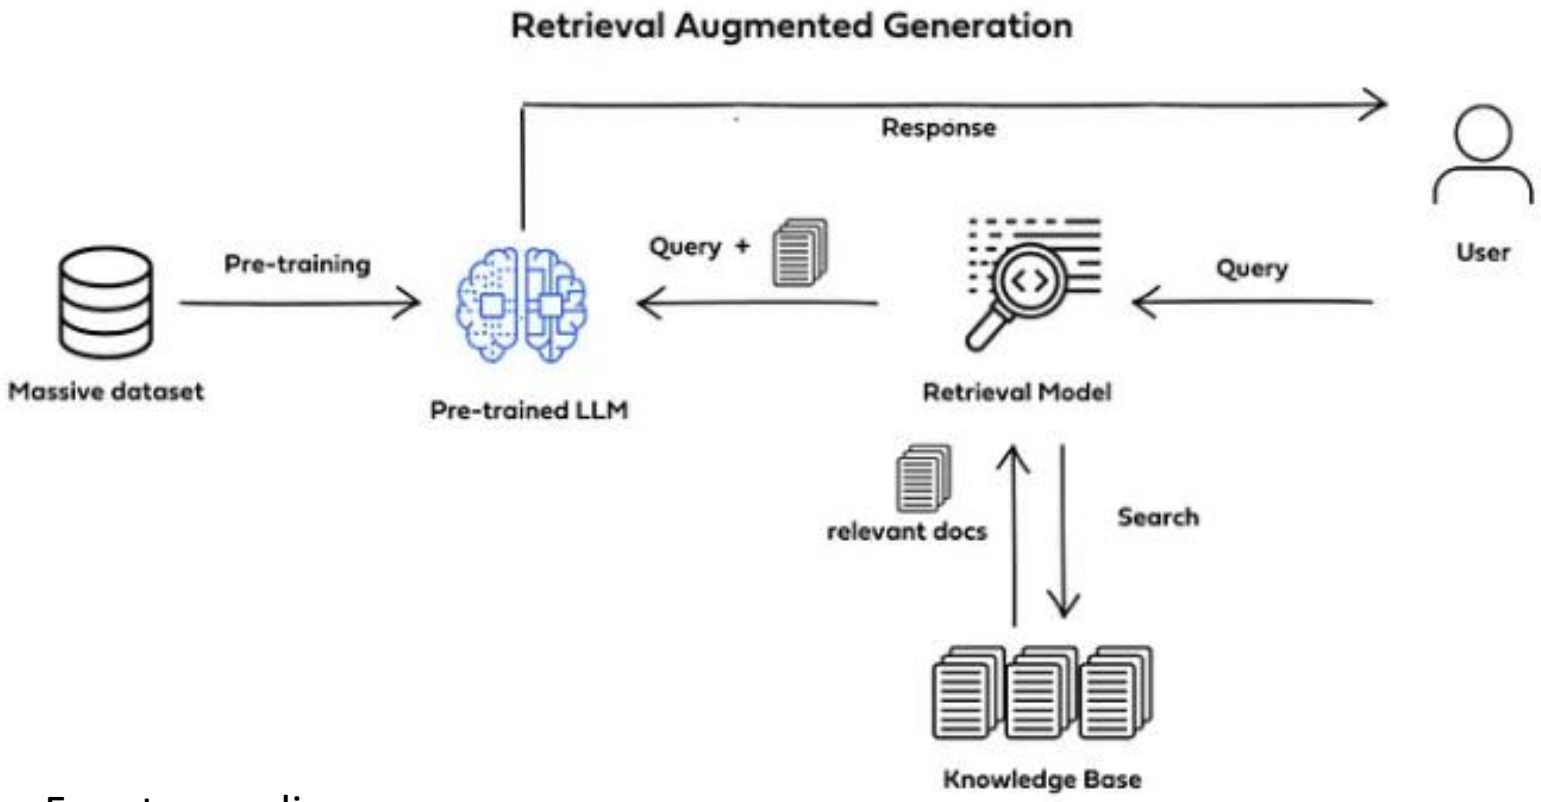

Fuente: medium

RAG Multimodal:

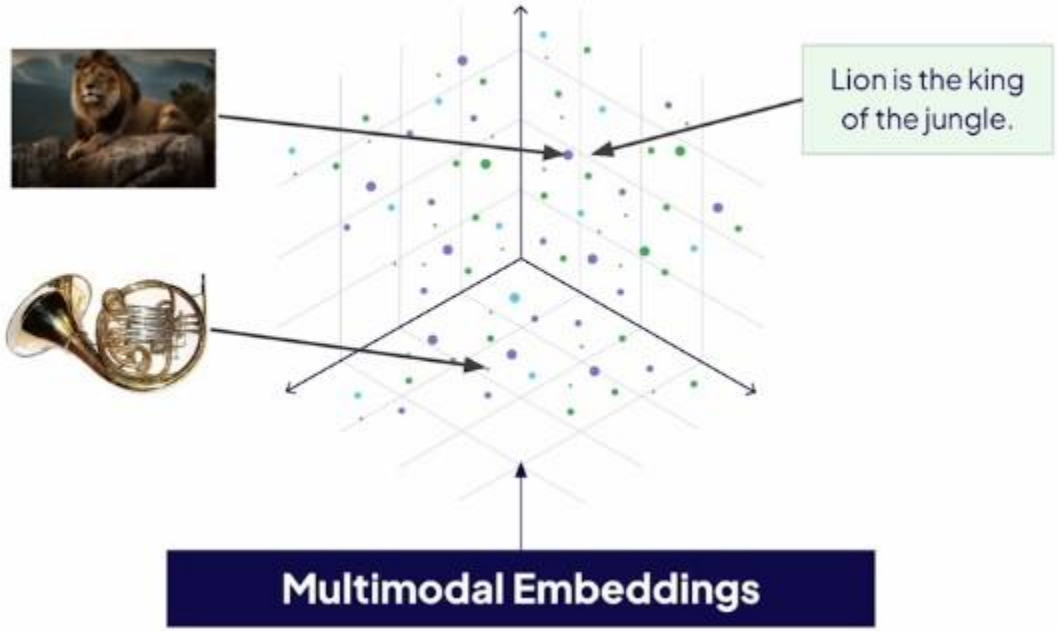

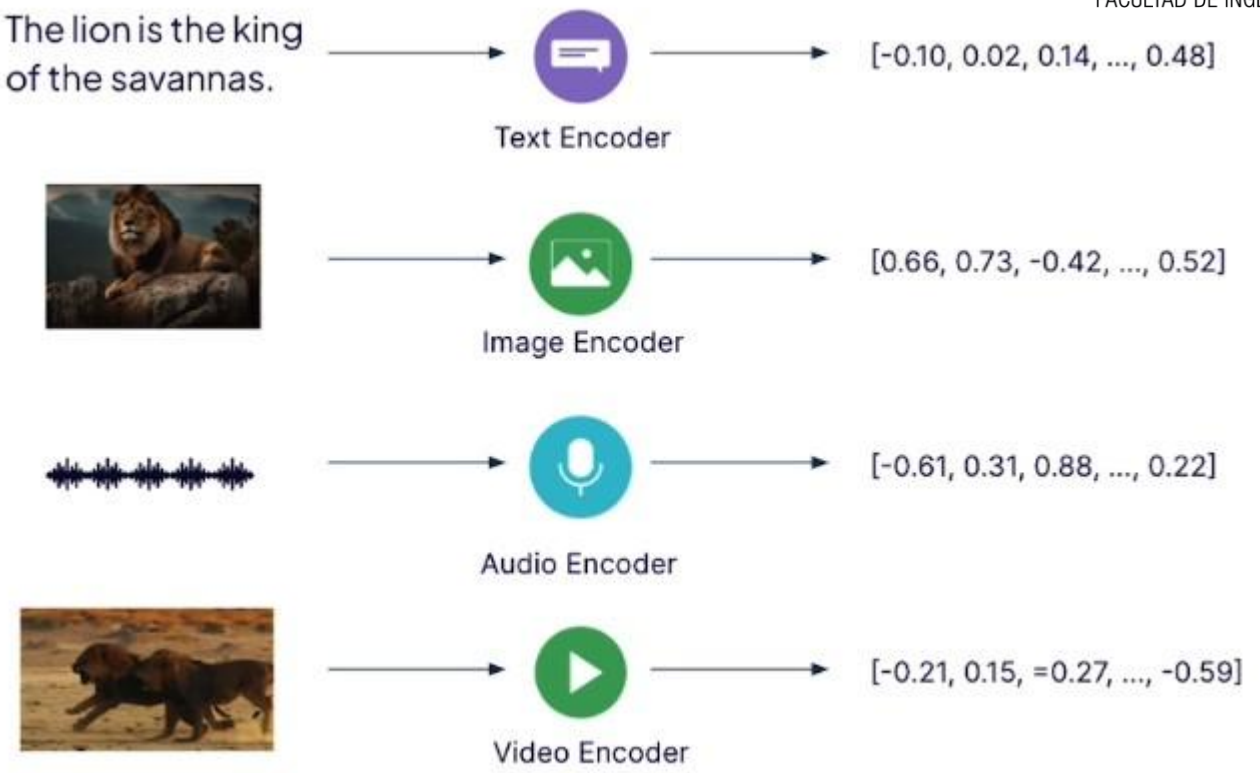

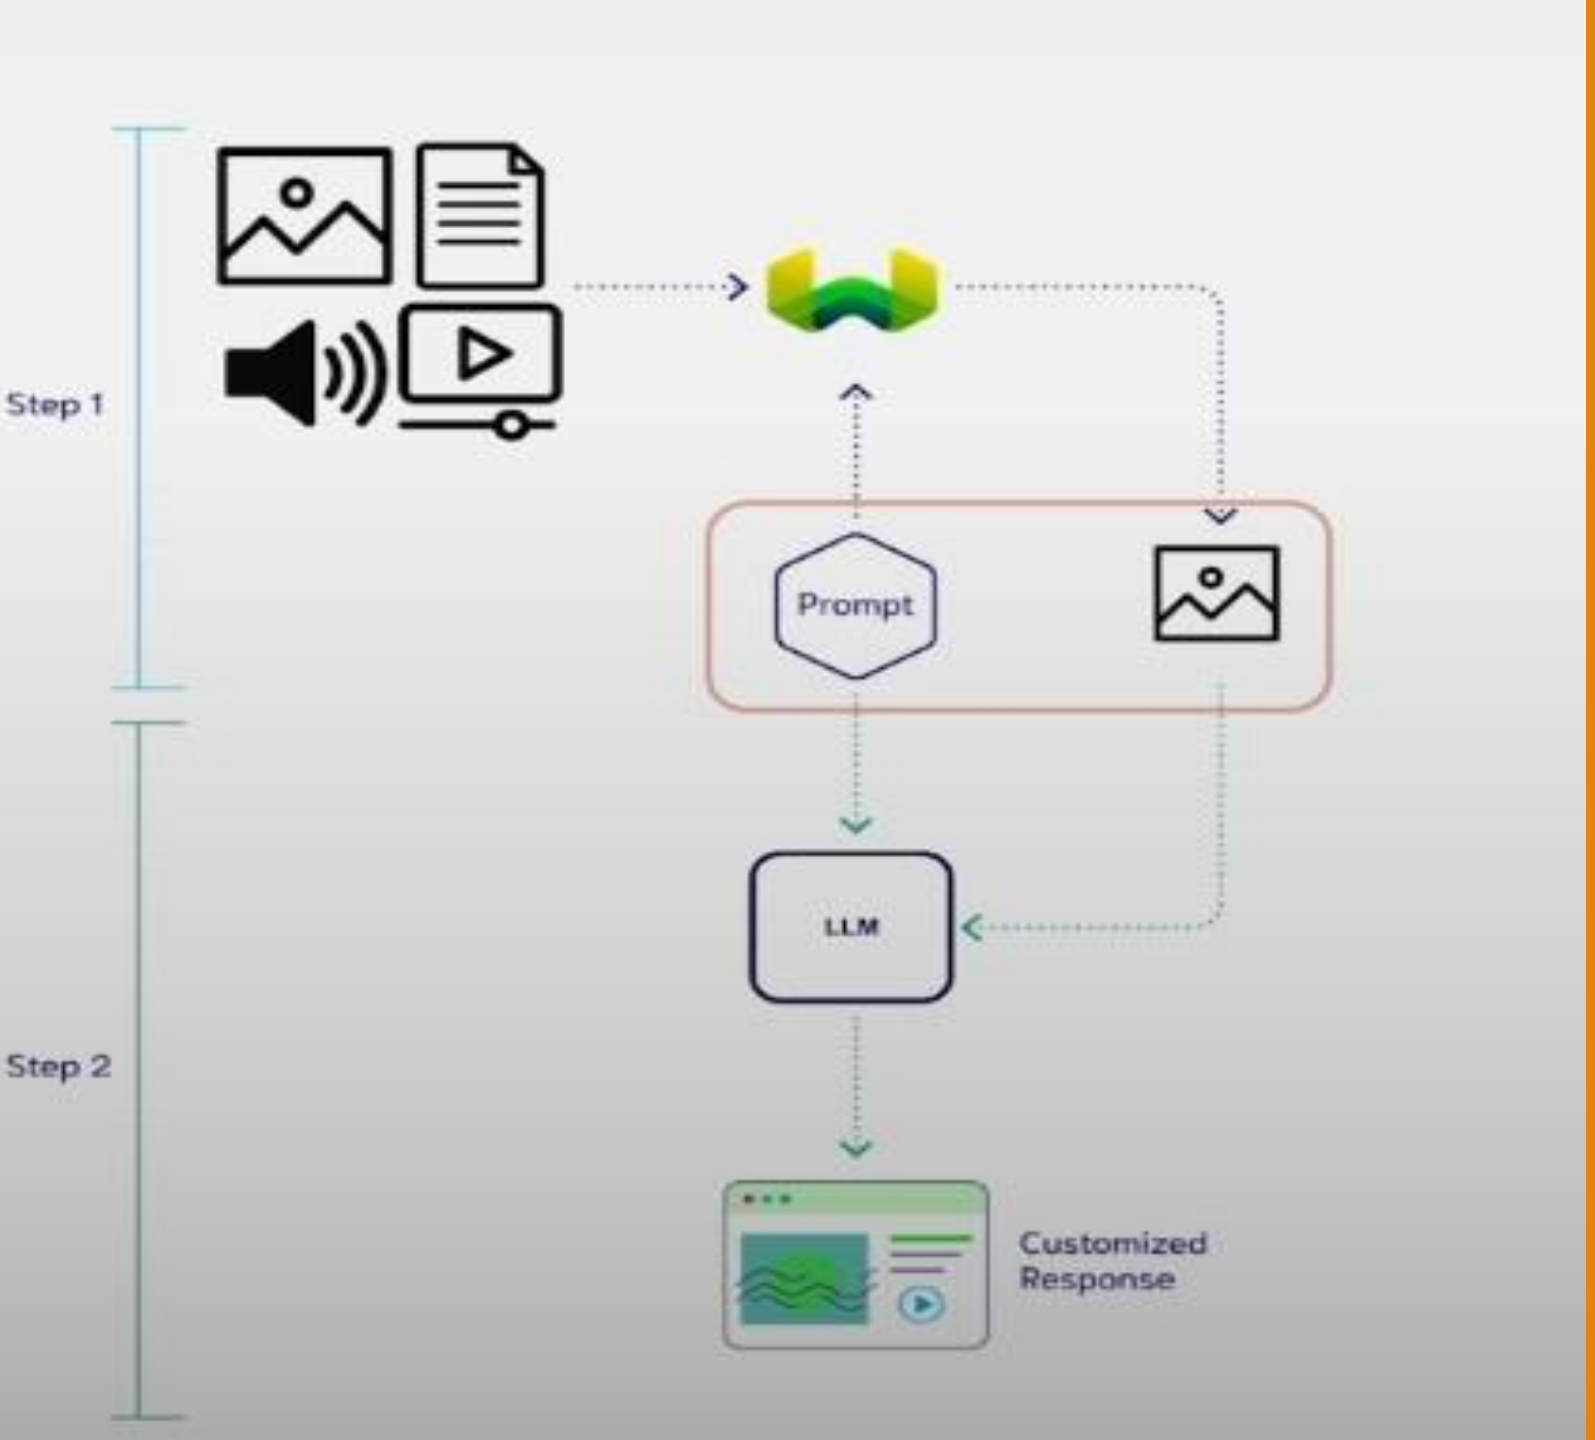

RAG Multimodal:

Ejemplo:
https://colab.research.google.com/drive/1o_h_GNH_cIwxe9G5ysvfKHGvpBZsXN8o?usp=sharing

Chatbots

- Simulación del contexto
- Memoria persistente gestionada programáticamente (Langchain)

Vemos el ejemplo de la implementación de un chatbot paso a paso!

Trabajo práctico Nro 2:

- Implementar un sistema de generación de texto (chatbot) que utilice la técnica de **Retrieval-Augmented Generation (RAG)**. En este ejercicio, el chatbot será capaz de recuperar información de una base de datos (o un conjunto de documentos) y usarla para generar respuestas más completas, mejorando la calidad de las respuestas generadas.
- **Entregables:** Link a repo público y captura de video de chatbot consultando al CV del alumno. Utilizar librería como Streamlit (para capturar pantalla se puede utilizar OBS por ejemplo, es open source). Link entregar: https://forms.gle/roAtRx2rXawaftjm7
- Se evalúa el código y la presentación (Repo con documentación).

Ejercicio en clase :

Pasos

0. Entregable: Esquematizar la solución en un diagrama de bloques (pueden utilizar excalidraw). Durante la clase o al finalizar al misma, enviar a Ezequiel.Guinsburg@gmail.com (uno por equipo nombrando a todos los integrantes).

1. Preparación del entorno de trabajo: contar con IDE, cuenta de Pinecone (Starter), cuenta de Groq.
2. Cargar los CVs de los miembros del equipo y obtener los vectores de embeddings (ejemplo de modelo de embeddings).
3. Cargar los vectores a Pinecone.
4. Probar hacer una pregunta y, por medio de una comparación coseno, obtener el vector más cercano.
5. Implementar un simple chatbot para obtener respuestas sobre el documento cargado (CV del alumno).