.UBAfiuba
FACULTAD DE INGENIERÍA

LLMs e IA Generativa
Clase 8

Optimización de LLMs.
LLMs de Razonamiento.
Model Context Protocol.
GenIA multimodal.
Overview Plataforma de Orquestación.

Mg. Ing. Ezequiel Guinsburg
ezequiel.guinsburg@gmail.com

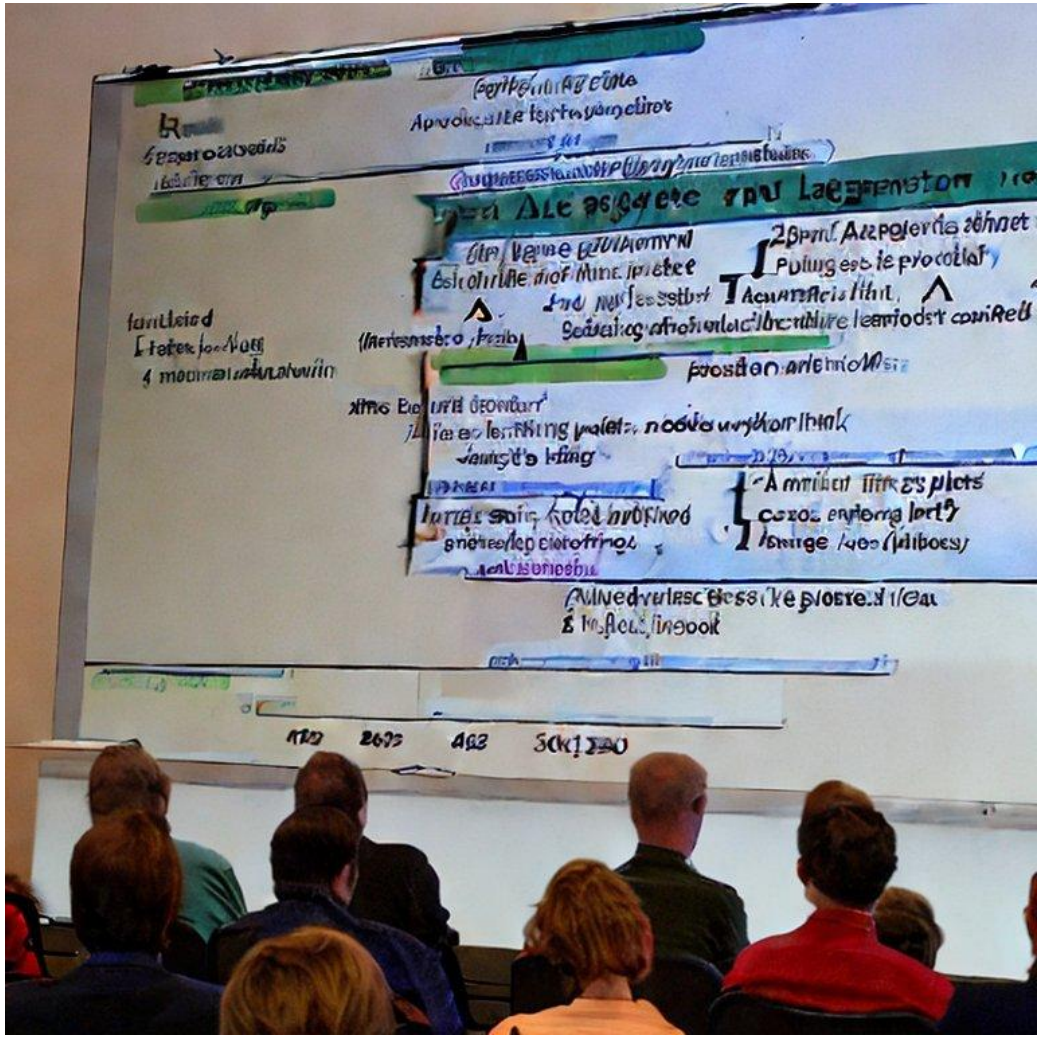

Temas:

- El camino de la optimización en el uso de los LLMs.
- LLMs de razonamiento.
- Model Context Protocol (MCP)
- I.A. generativa multimodal.
  - Ejemplo teórico de modelo de texto-imagen.
  - Ejemplo práctico.
- Plataformas de Orquestación de Alto Nivel.
- Trabajo en clase: Orquestación con LLMs.

Referencias:

1. Paper Reasoning With LLMs, a Survey
2. Model Context Protocol: Landscape, Security Threats and Future Research Directions.- https://arxiv.org/pdf/2503.23278
3. Paper Visual Instruction Tuning - Haotian Liu
4. Paper Hicherical Text-Conditional Image Generation with CLIP Latents - https://arxiv.org/pdf/2204.06125
5. Denoising Diffusion Probabilistic Models - https://arxiv.org/pdf/2006.11239

¿Cómo “funciona” realmente la inteligencia en modelos modernos?

.UBAfiuba FACULTAD DE INGENIERÍA

1 LLM Reasoning

✗ No razonan internamente

✓ **Reasoning WITH LLMs**
- prompts
- estructura (CoT, ToT)
- control externo

El sistema induce el razonamiento, no el modelo por sí mismo.

2 Multimodal Models

✗ No “ven” profundamente

✓ **Understanding WITH alignment**
- instruction tuning
- datos sintéticos
- alineación con lenguaje

Aprenden a seguir instrucciones sobre lo que “perciben”.

3 Representación (CLIP / DALL·E 2)

✗ No generan desde texto

✓ **Generan desde embeddings**
- texto → espacio semántico → imagen
- el significado vive en el latent space

El problema no es generar píxeles, es generar el significado correcto.

4 Diffusion Models

✗ No crean directamente

✓ **Refinan iterativamente**
- ruido → estructura → detalle
- muchos pasos simples
- descompresión progresiva

La complejidad no se elimina, se distribuye en el tiempo.

IDEA UNIFICADORA

La inteligencia no está en el modelo aislado… está en el sistema que lo rodea.

LOS INGREDIENTES CLAVE QUE COMBINAN ESTOS SISTEMAS

1. REPRESENTACIONES
- espacios latentes compartidos
- semántica comprimida
- contenido y estilo abstractos

2. PROCESOS
- iteración (diffusion, reasoning)
- pasos simples acumulativos
- refinamiento progresivo
- búsqueda y exploración

3. CONTROL
- prompts e instrucciones
- herramientas (tools)
- verificación y evaluación
- alineación (RLHF, datos)

No diseñamos inteligencia directa.
Diseñamos estructuras donde la inteligencia emerge.

Prompting Vs. RAG Vs. Fine tuning

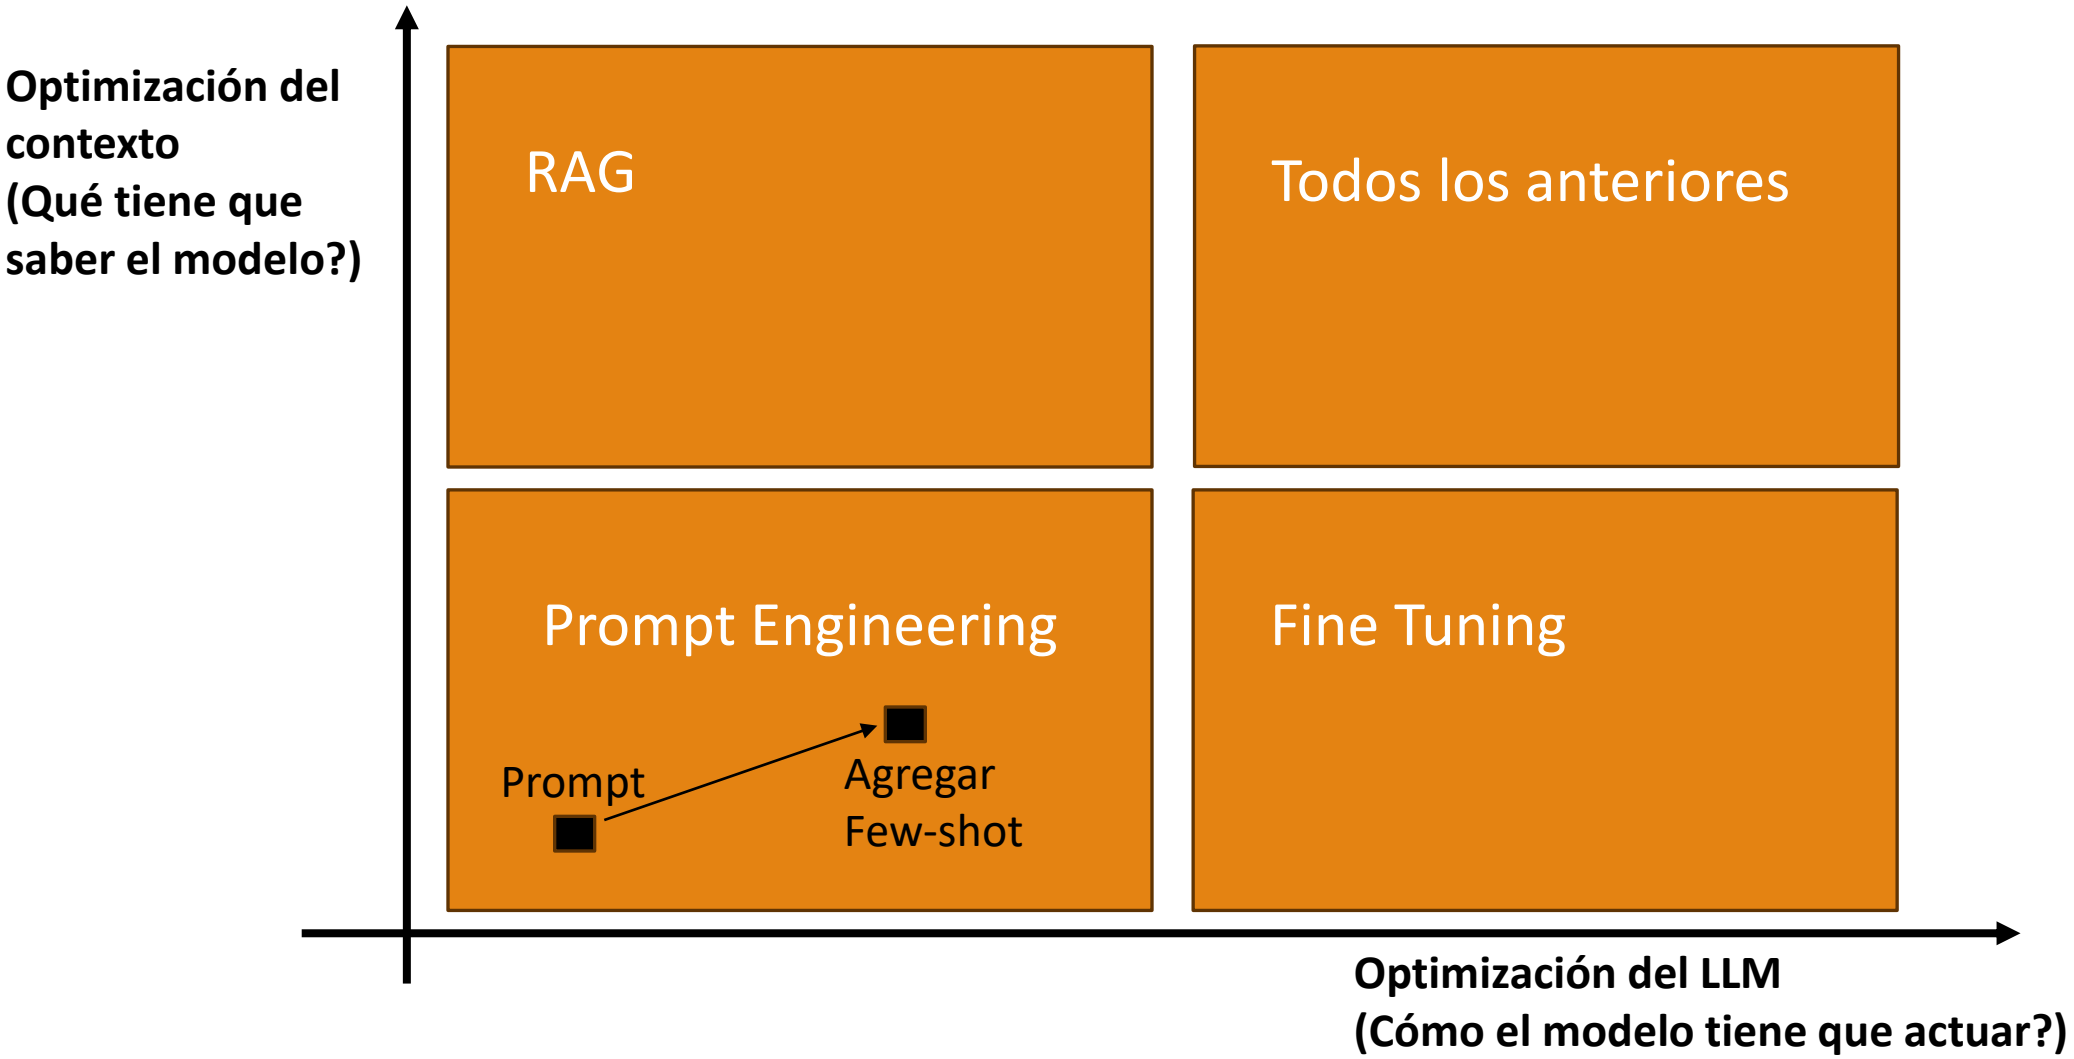

Prompting vs. RAG vs. Fine-tuning

.UBA fiuba FACULTAD DE INGENIERÍA

1. PROMPT ENGINEERING (Prompting)

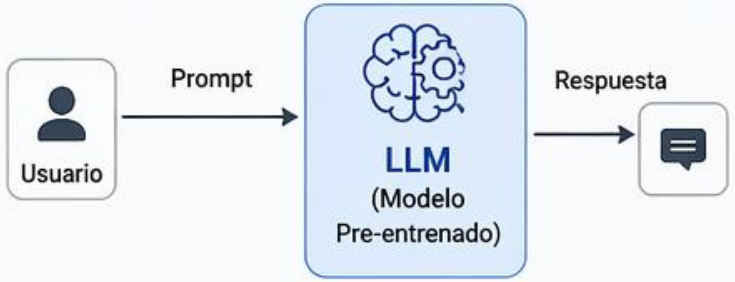

¿CÓMO FUNCIONA?

El usuario diseña instrucciones (prompts) claras y detalladas para guiar al modelo en cada interacción.

BUENO PARA:

- Testear y aprender rápidamente.
- Cuando se utiliza y se evalúa nos da
- una idea de cómo optimizar.

MALO PARA:

- Introducir nueva información.
- Replicar consistentemente un estilo o método (i.e. aprender un nuevo lenguaje de programación).
- Minimizar el uso de tokens.

2. RAG (Retrieval-Augmented Generation)

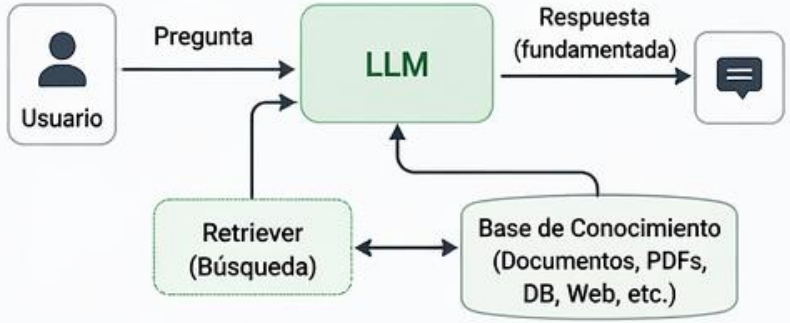

¿CÓMO FUNCIONA?

El modelo busca información relevante en una base de conocimiento externa y la usa como contexto para generar respuestas más precisas y actualizadas.

BUENO PARA:

- Introducir nueva información sin re-entrenar el modelo.
- Respuestas actualizadas y verificables (con fuentes).
- Mantener el conocimiento fuera del modelo.
- Reducir alucinaciones.

MALO PARA:

- Requiere buena base de conocimiento y buen retriever.
- Depende de la calidad de los documentos.
- Puede aumentar el tiempo de respuesta.

3. FINE-TUNING (Ajuste Fino)

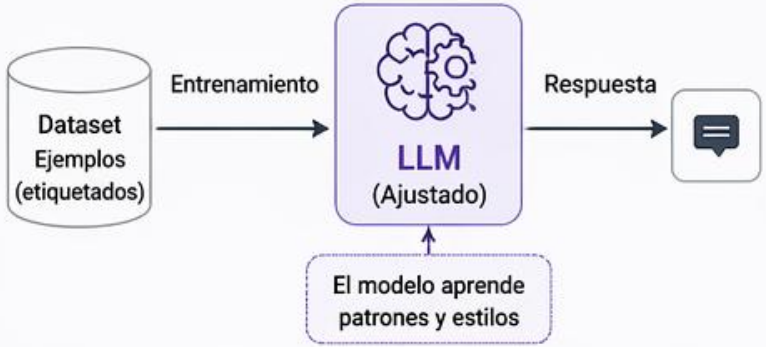

¿CÓMO FUNCIONA?

Se entrena el modelo con datos específicos para que aprenda nuevos patrones, estilos o comportamientos.

BUENO PARA:

- Replicar consistentemente un estilo o método.
- Dominio específico (médico, legal, código, etc.).
- Reducir tokens (respuestas más cortas y directas).
- Automatizar tareas muy específicas.

MALO PARA:

- Costoso en tiempo y recursos.
- Requiere datos de entrenamiento de calidad.
- Menos flexible ante cambios o nueva información.

LLMs de Razonamiento

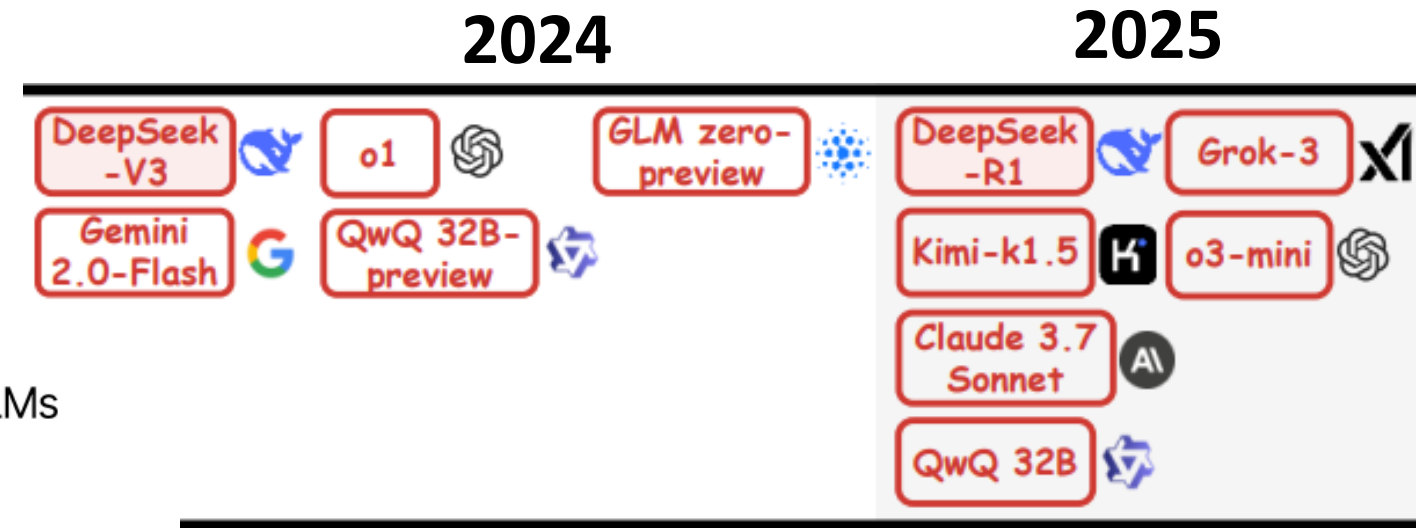

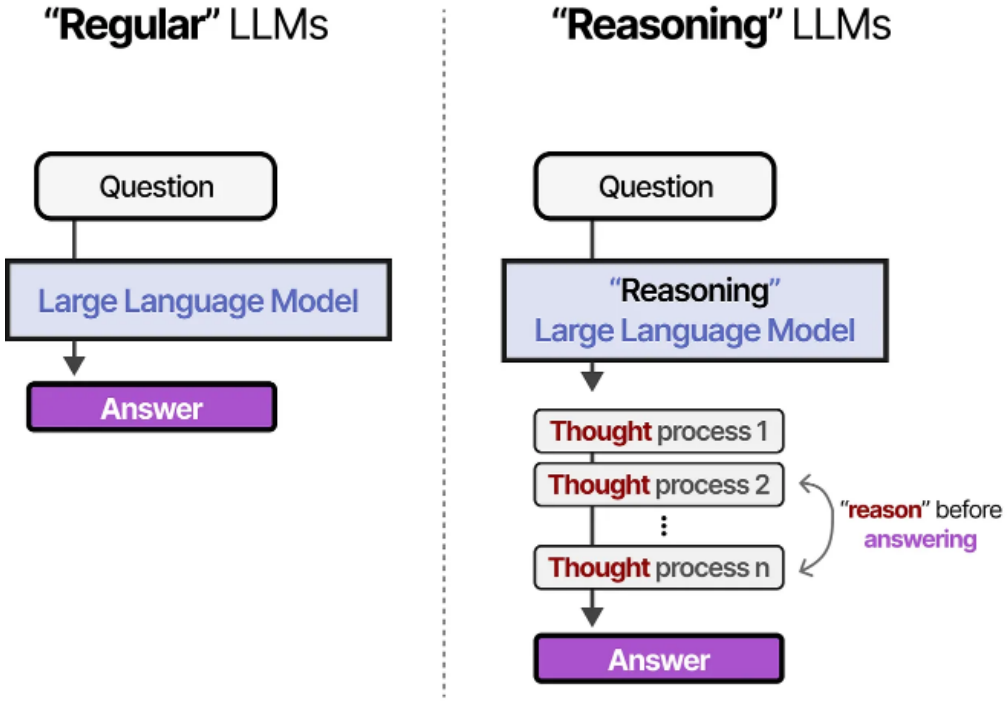

¿CÓMO FUNCIONAN LOS MODELOS CON RAZONAMIENTO?

No responden de inmediato: piensan, analizan y organizan antes de dar la respuesta final.

1. ENTRADA DEL USUARIO

¿Cuál es la mejor estrategia para reducir el churn de clientes en una SaaS B2B?

El modelo entiende el objetivo

Identifica que debe analizar el problema, considerar factores clave y proponer una solución basada en su conocimiento.

2. PROCESO DE RAZONAMIENTO INTERNO

El modelo descompone el problema y realiza pasos intermedios de pensamiento.

1. Comprende el problema

Identifica que el objetivo es reducir el churn en una SaaS B2B.

2. Recupera y analiza información

Recuerda conceptos relevantes: onboarding, valor percibido, soporte, uso del producto, precios, etc.

3. Genera hipótesis y opciones

Considera diferentes estrategias posibles y sus posibles impactos.

4. Evalúa y conecta ideas

Compara opciones, identifica relaciones causales y elige las más efectivas.

5. Planifica la respuesta

Organiza la respuesta final con estructura clara y argumentos sólidos.

CADENA DE PENSAMIENTO (Chain of Thought)

"Primero entiendo el problema... luego analizo factores clave... después considero opciones... evalúo cuál tiene más impacto y finalmente estructuro la respuesta."

3. RESPUESTA FINAL

Para reducir el churn en una SaaS B2B, las estrategias más efectivas suelen ser:

- Mejorar el onboarding
- Aumentar el valor percibido
- Promover adopción del producto
- Ofrecer soporte proactivo
- Revisar precios y planes

La clave es actuar sobre los factores que más impactan en el valor y la retención.

Respuesta final basada en razonamiento

No es una respuesta memorizada, sino el resultado de un proceso de análisis y conexión de ideas.

CARACTERÍSTICAS CLAVE

PENSAMIENTO PASO A PASO

Descompone problemas complejos en pasos manejables.

CONECTA INFORMACIÓN

Relaciona conceptos, recupera conocimiento y lo aplica al contexto.

EVALÚA OPCIONES

Compara alternativas y elige la mejor según criterios relevantes.

PLANIFICA RESPUESTAS

Organiza la información de forma lógica, clara y útil.

¿DÓNDE SON MÁS ÚTILES?

Programación | Ciencia | Análisis de datos | Tareas complejas

Los modelos con razonamiento no solo generan texto: PIENSAN ANTES DE RESPONDER.

Esto permite respuestas más precisas, coherentes y útiles en problemas complejos.

Referencia: https://platform.openai.com/docs/guides/reasoning

MCP – Que es y para que sirve (origen)

Model Context Protocol: estándar para que los modelos de IA interactúen de forma segura y uniforme con herramientas, datos y sistemas externos.

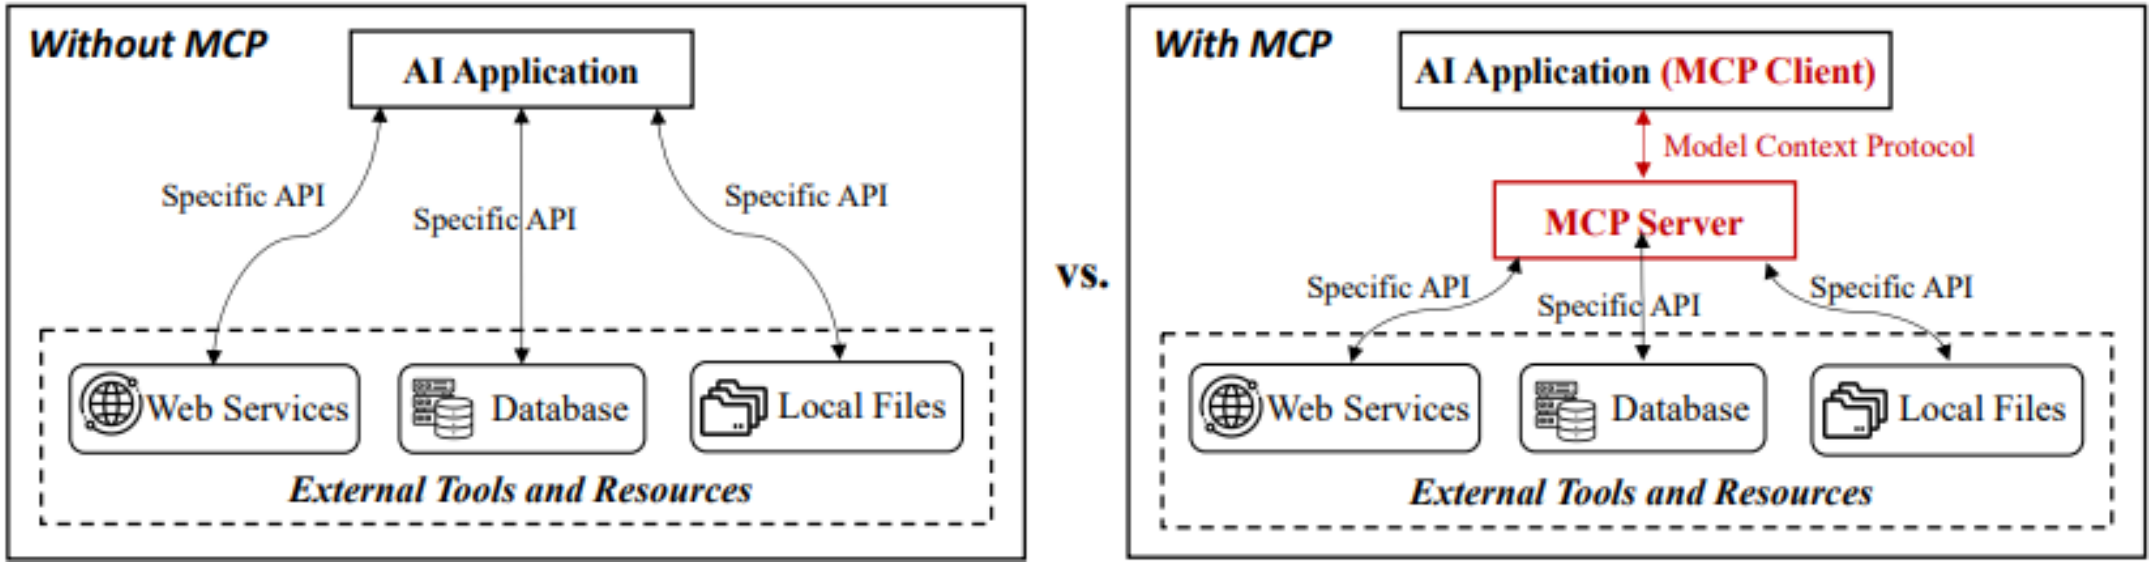

MCP – Arquitectura y flujo de trabajo

Roles: Host (app que corre la experiencia), Cliente (orquesta y conversa) y Servidor (exposición de capacidades).

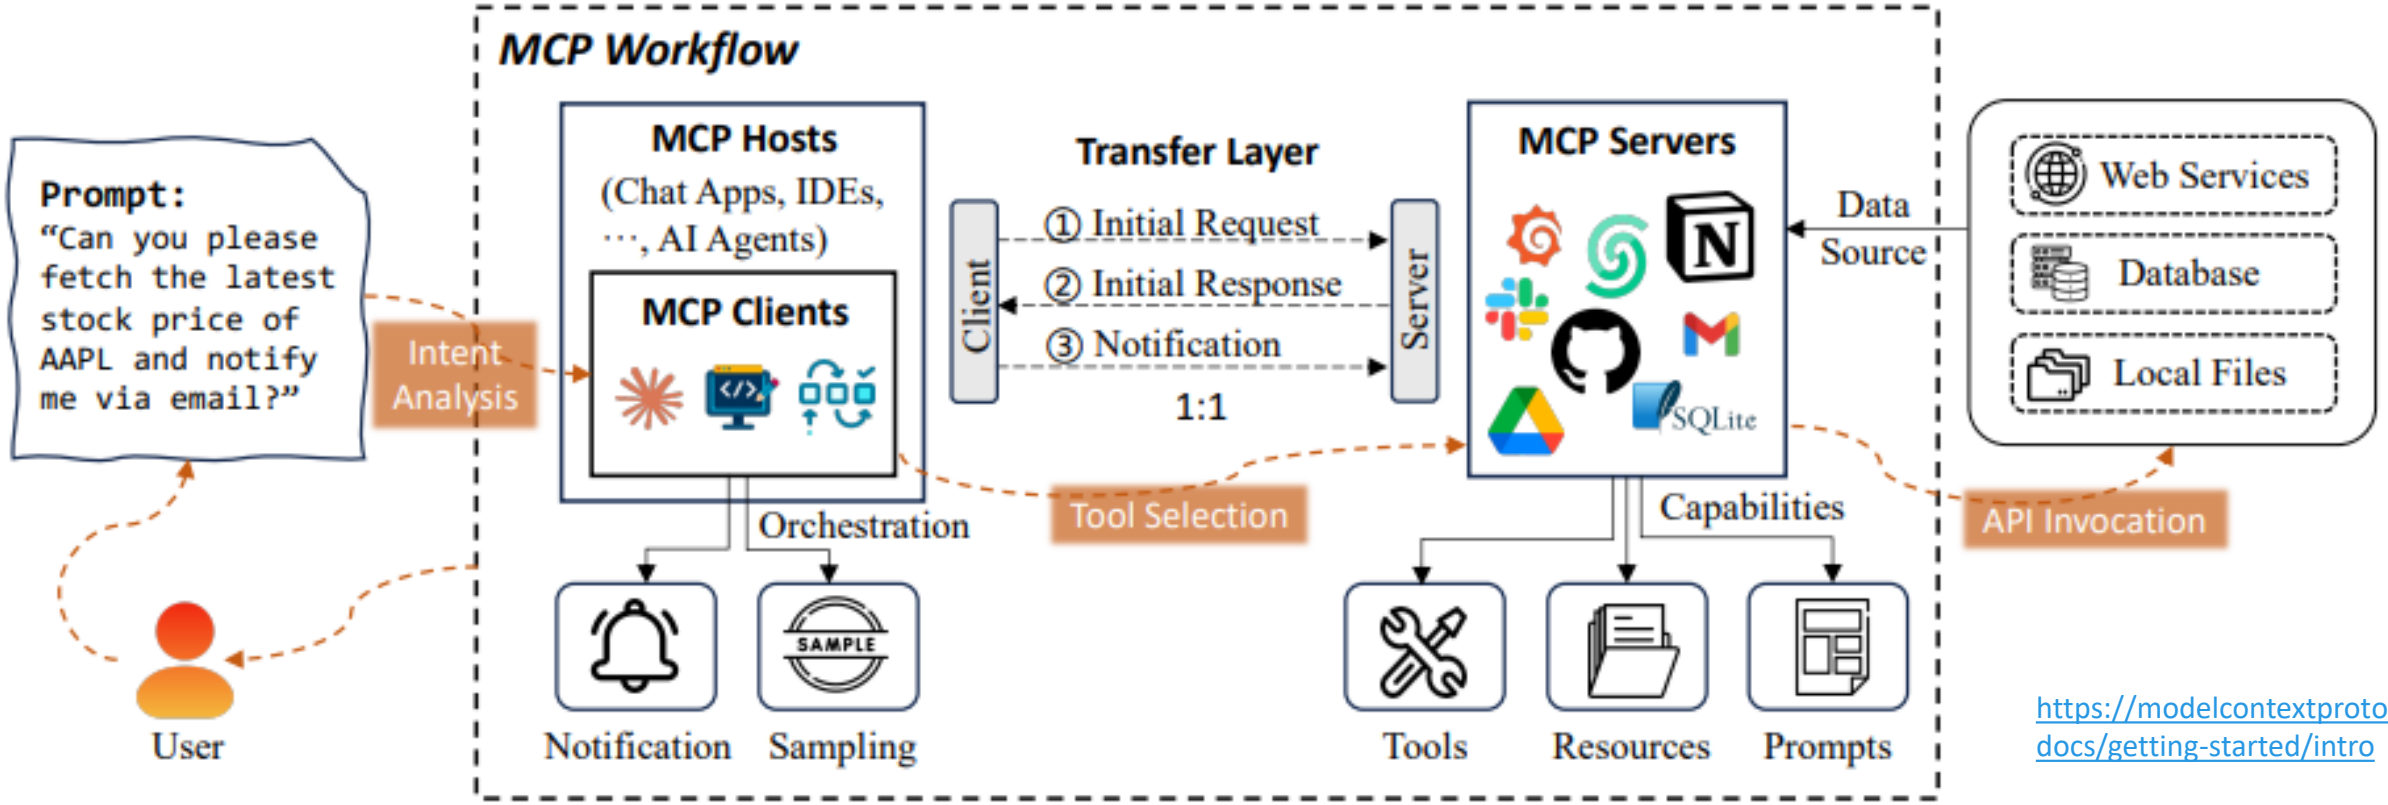

https://modelcontextprotocol.io/docs/getting-started/intro

ECOSISTEMA MCP: CATEGORÍAS, PRODUCTOS Y CASOS DE USO

CATEGORÍA	COMPAÑÍAS / PRODUCTOS	FUNCIONES / CASOS DE USO
1. MODELOS Y FRAMEWORKS DE IA Proveedores de modelos y frameworks que soportan MCP y sus capacidades.	ANTHROPIC Claude OpenAI Baidu Maps Blender MCP	Soporte MCP en versión desktop y SDK, integración API (ej. geolocalización), generación 3D con comandos en lenguaje natural.
2. HERRAMIENTAS DE DESARROLLO Herramientas que facilitan el desarrollo, integración y gestión de servidores MCP.	Replit MS Copilot Studio Sourcegraph Cody Codeium Cursor Cline	Entornos con integración MCP, soporte para asistentes de código, ejecución en VS Code, gestión de servidores/herramientas MCP.
3. IDES / EDITORES Editores e IDEs que integran MCP para mejorar la productividad y el desarrollo asistido.	Zed JetBrains Windsurf Editor Theia/IDE Emacs MCP OpenSumi	Comandos y tooling MCP en IDEs, soporte AI, integración transparente de herramientas y automatización de flujos de trabajo.
4. PLATAFORMAS Y SERVICIOS CLOUD Plataformas cloud que ofrecen infraestructura y servicios para aplicaciones MCP.	Cloudflare Block (Square) Stripe	Hosting de servidores MCP, integración OAuth, APIs expuestas para plataformas financieras y servicios escalables.
5. AUTOMATIZACIÓN WEB Y DATOS Herramientas para automatización, pruebas y conexión a datos y APIs mediante MCP.	Apify MCP Tester LibreChat Ecosistema de herramientas y conectores de datos	Conexión a servidores MCP vía SSE, ecosistema de herramientas ampliado para scraping, tests, chatbots y análisis de datos.

MCP conecta modelos de IA, herramientas, plataformas y datos en un ecosistema abierto e interoperable, permitiendo automatización, integración y nuevas experiencias impulsadas por IA.

I.A. generativa multimodal

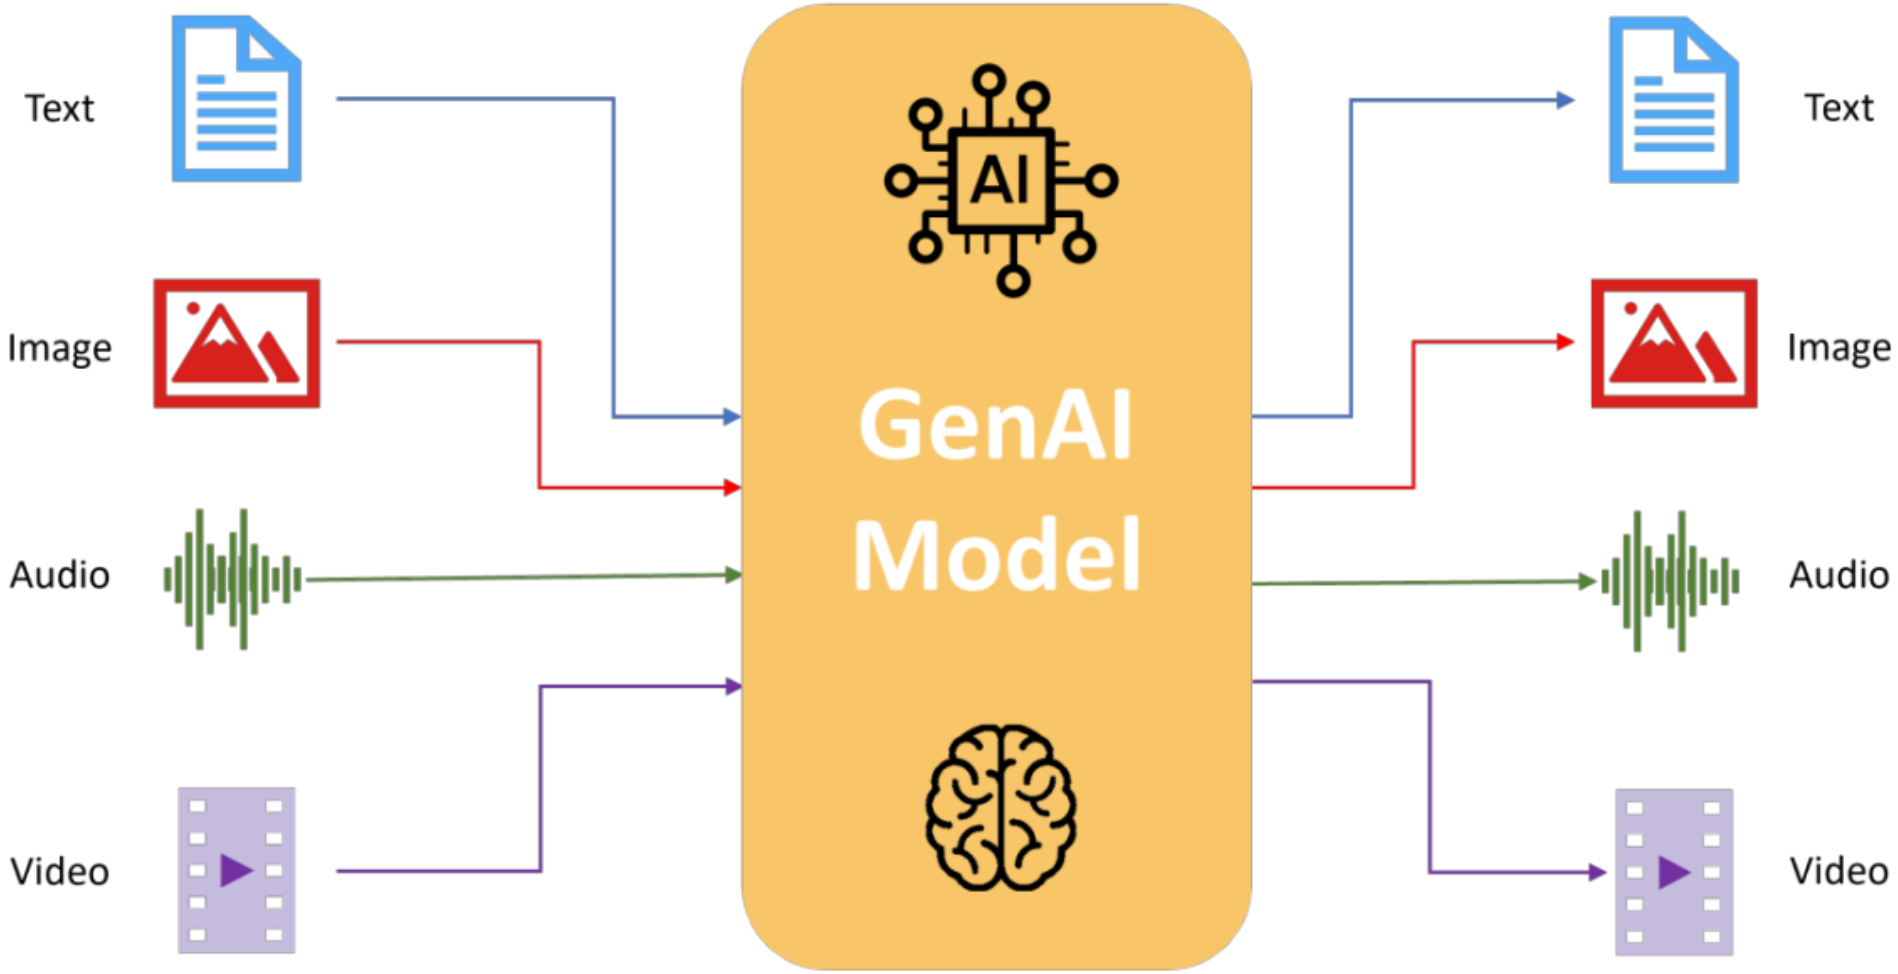

EVOLUCIÓN DE MODELOS DE IA GENERATIVA MULTIMODAL (2022 → 2026)

De modelos que perciben a sistemas que razonan, entienden y actúan en el mundo real.

2022 — PERCEPCIÓN MULTIMODAL INICIAL

Primeros modelos que combinan visión y lenguaje.

- **Flamingo** (DeepMind) — Conecta imágenes y texto en contexto.
- **Kosmos-1** (Microsoft) — Comprensión visual y lenguaje.
- **LLaVA** (UW) — Modelo visual conversacional de código abierto.
- **VIMA** (NVIDIA) — Agente visual multimodal para robótica.

Enfoque: entender imágenes y texto estático.

2023 — EXPLOSIÓN MULTIMODAL

Gran salto en capacidades y diversidad de modalidades.

- **GPT-4V** (OpenAI) — Comprensión visual avanzada en GPT-4.
- **Gemini 1.0** (Google) — Modelo nativo multimodal desde el inicio.
- **MM1** (Apple) — Modelo multimodal masivo y coherente.
- **Claude 3** (Anthropic) — Comprensión visual sólida con contexto largo.
- **Chameleon** (Meta) — Adaptación eficiente entre modalidades.
- **Video-LLaMA** (Alibaba) — Comprensión y razonamiento sobre video.

Enfoque: integrar múltiples modalidades con mayor calidad.

2024 — MULTIMODAL EN TIEMPO REAL

Modelos más potentes, con audio, video y capacidades en tiempo real.

- **GPT-4o** (OpenAI) — Texto, imagen, audio y video en tiempo real.
- **Gemini 1.5** (Google) — Ventana de contexto masiva y multimodal.
- **Claude 3.5** (Anthropic) — Mejor razonamiento y comprensión multimodal.
- **InternVL 2.5** (Open Source) — Comprensión visual multilingüe de alto nivel.
- **Qwen-VL** (Alibaba) — Comprensión visual avanzada y localización precisa.
- **Llama 3 Vision** (Meta) — Capacidades visuales integradas en Llama 3.

Enfoque: tiempo real, audio, video, contextos largos y mayor precisión.

2025 – 2026 — MODELOS UNIFICADOS + AGENTES INTELIGENTES

Modelos unificados, razonamiento avanzado, agentes y acción en el mundo real.

- **GPT-5.x** (OpenAI) NUEVO — Razonamiento avanzado, herramientas, memoria y multimodal unificado.
- **Gemini 3 / 3.1** (Google) NUEVO — Multimodal nativo, agentes, planificación y contexto 1M+ tokens.
- **Claude 4** (Anthropic) NUEVO — Mayor precisión, contexto largo y razonamiento profundo.
- **Qwen2-VL** (Alibaba) NUEVO — SOTA en comprensión visual open source, video y documentos.
- **InternVL 3** (Open Source) NUEVO — Multimodal generalista con gran rendimiento en múltiples idiomas.
- **Gemma 2** (Google Open) NUEVO — Modelo abierto y eficiente con capacidades multimodales.

Enfoque: razonamiento + acción + herramientas + multimodalidad unificada y agentes autónomos.

MODALIDADES

- Texto
- Imagen
- Video
- Audio
- 3D / Espacial
- Sensores / Otros

TENDENCIAS CLAVE

- Contextos cada vez más largos y complejos
- Modelos nativos multimodales de extremo a extremo
- Razonamiento y agentes multimodales
- Modelos abiertos cada vez más competitivos
- Aplicaciones en tiempo real y en múltiples dispositivos

LA EVOLUCIÓN EN UNA MIRADA

VER — Modelos que perciben imágenes y texto. →
ENTENDER — Integran múltiples modalidades y contexto. →
RAZONAR — Comprenden, conectan ideas y resuelven problemas complejos. →
ACTUAR — Toman decisiones, usan herramientas y generan impacto en el mundo real.

La IA generativa multimodal evoluciona rápidamente hacia modelos más unificados, inteligentes y útiles.
De sistemas que ven el mundo, a sistemas que lo entienden, razonan y transforman.

I.A. generativa multimodal – Ejemplo de modelo

Generación de imágenes condicionada por embeddings de texto.
Encoder (CLIP) – Decoder (Difussion model). **[unCLIP]**
Se utiliza el estado latente del modelo CLIP para manipular los embeddings y sacar distintos tipos de imagen

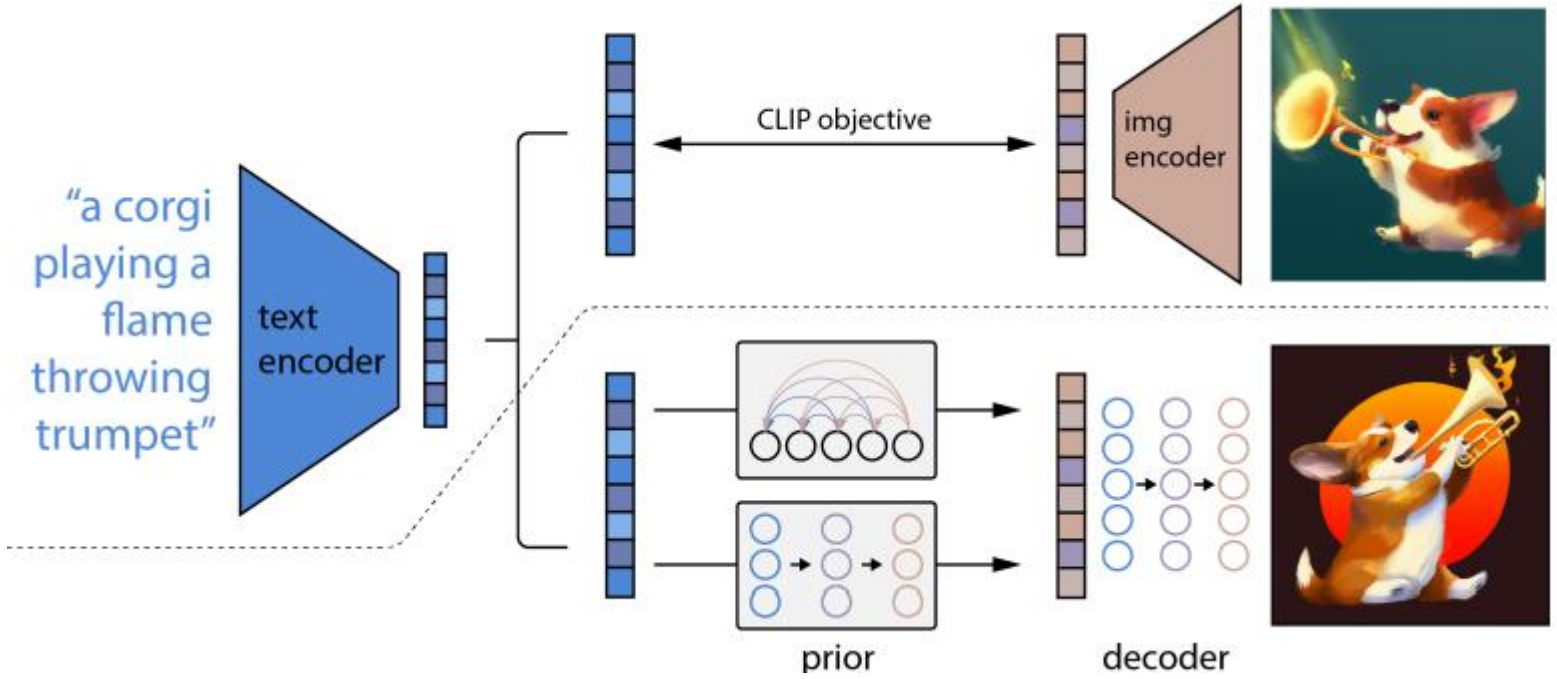

I.A. generativa multimodal – Ejemplo de modelo

Dataset de entrenamiento *(x, y)*

x = imágenes | ***y*** = descripciones

$\boldsymbol{z_i}$ = embeddings de imagen | $\boldsymbol{z_t}$ = embeddings de texto

Se utilizan dos componentes:

prior $\mathbf{P}(\boldsymbol{z_i} \mid \boldsymbol{y})$ = produce los embeddings de imagenes CLIP

decoder $\mathbf{P}(\boldsymbol{x} \mid \boldsymbol{z_i}, \boldsymbol{y})$ = produce las imágenes *x* condicionadas a z_i e *y*

Combinando los dos componentes tenemos el modelo generativo de imágenes ***x*** dado las descripciones ***y***:

$$P(x|y) = P(x, z_i|y) = P(x|z_i, y)P(z_i|y)$$

I.A. generativa multimodal – Ejemplo de modelo

Reconstrucción de imágenes a partir de espacios latentes reducidos

Trabajo comparativo de modelos:
https://distill.pub/2021/multimodal-neurons/

Repositorio del código para utilizar:
https://github.com/Stability-AI/stablediffusion

I.A. generativa multimodal
Ejemplos

Ejemplo : (text2img)
https://huggingface.co/CompVis/stable-diffusion-v1-4

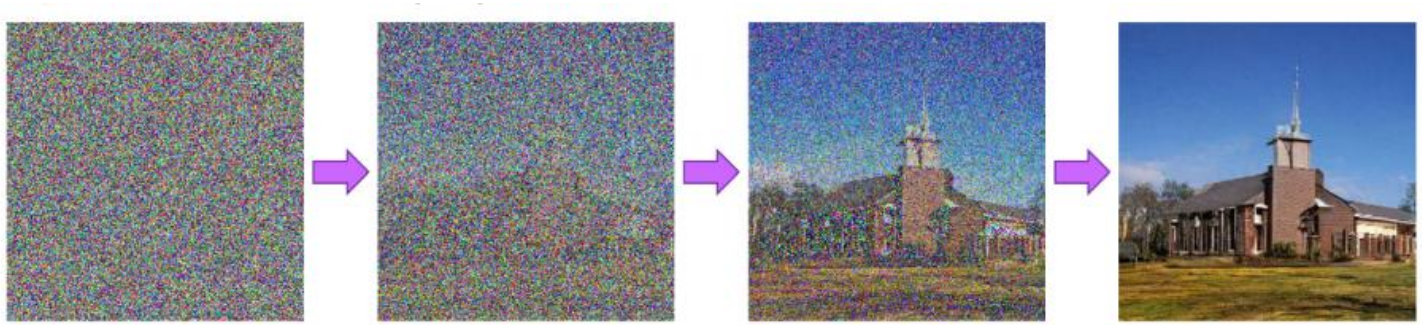

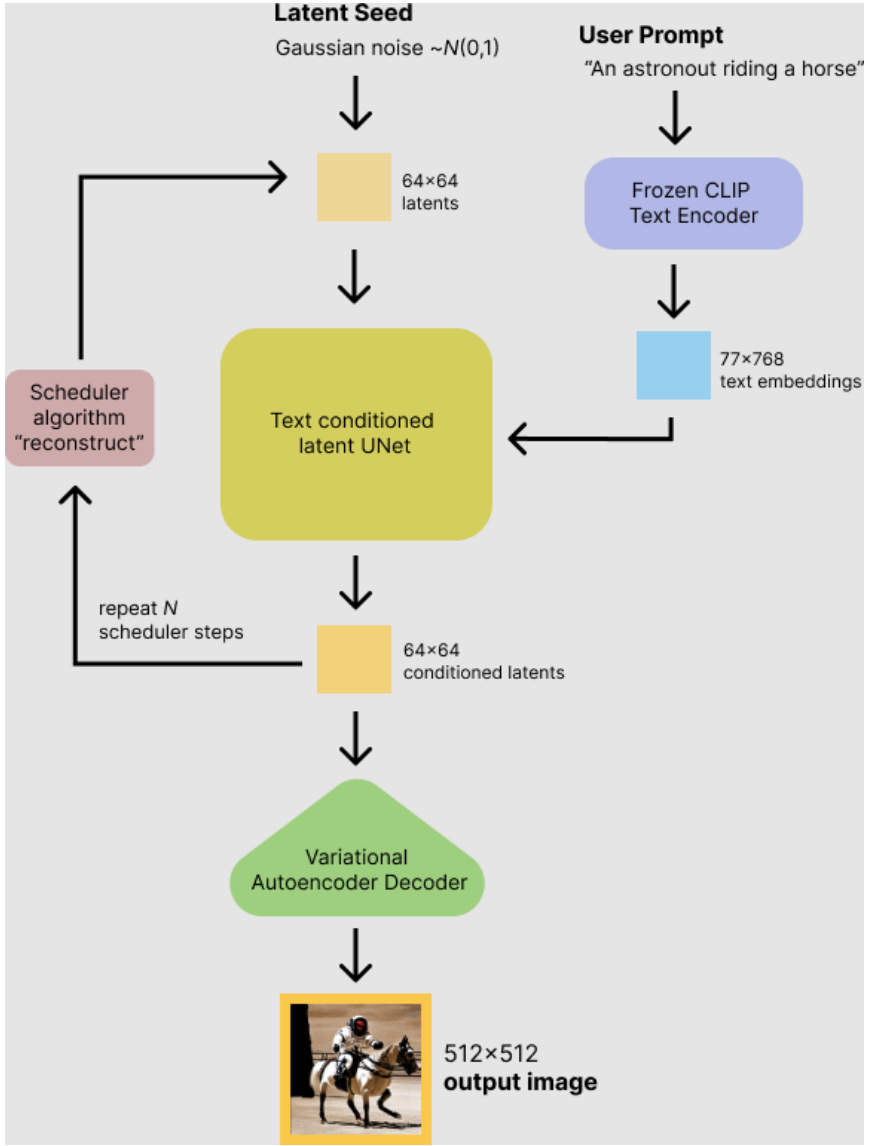

I.A. generativa multimodal
Ejemplos

Ejemplo JANUS (Entendimiento Multimodal)
https://huggingface.co/deepseek-ai/Janus-1.3B
(https://arxiv.org/pdf/2410.13848)

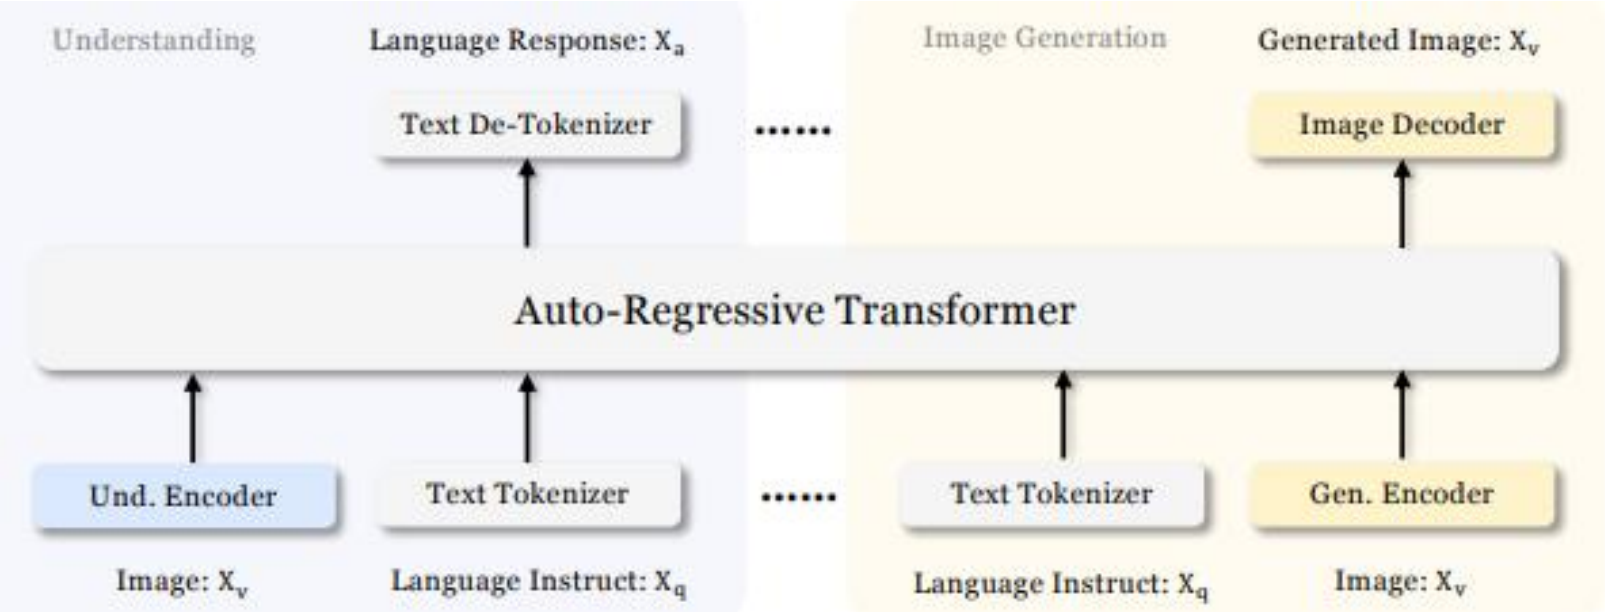

Plataforma	Enfoque / Modelo de uso	Capacidad IA / LLM	Complejidad / Perfil usuario	Arquitectura	Costos / Licenciamiento
n8n	Automatización de workflows y orquestación de procesos. Enfoque técnico, muy flexible y extensible.	Integración con +200 LLMs (OpenAI, Anthropic, etc.) Nodos de IA (agentes, resumen, embeddings, etc.) Soporta RAG y herramientas personalizadas	Alta Usuarios técnicos, desarrolladores y equipos de ingeniería.	Self-hosted (opción principal) o nube (n8n Cloud). Altamente extensible con JavaScript/TypeScript.	Versión Cloud: desde €20/mes (Starter) Self-hosted: Gratis (open source) Enterprise: desde €1.080/mes
zapier	Automatización sin código entre aplicaciones. Enfoque en simplicidad y velocidad.	Integración con IA vía Zapier AI Actions Conexión con OpenAI, Claude, Gemini, etc. Automatiza tareas con IA sin programar	Baja a Media Usuarios no técnicos, negocios, marketing, operaciones.	100% en la nube (SaaS). No requiere infraestructura propia.	Planes desde US$19,99/mes Pago por tareas (zaps) Escalable por volumen.
Make	Automatización visual y orquestación de procesos complejos. Enfoque balanceado entre potencia y facilidad.	Módulos nativos de IA (OpenAI, Anthropic, etc.) Soporta RAG, detección de texto, clasificación, etc. Permite llamar APIs de IA en flujos visuales	Media Usuarios técnicos y equipos que buscan flexibilidad visual.	100% en la nube (SaaS). Infraestructura administrada por Make.	Planes desde US$9/mes Pago por operaciones Escalable por volumen.
Pipedream	Automatización como código (eventos, APIs y data workflows). Enfoque para desarrolladores.	Soporta LLMs y IA vía APIs Funciones serverless para procesamiento con IA Ideal para construir automatizaciones con lógica personalizada	Alta Desarrolladores que prefieren código y control total.	100% en la nube (Serverless). Se ejecuta en entorno serverless.	Plan gratuito disponible Planes desde US$10/mes Pago por invocaciones y tiempo de ejecución.
NUEVO Dify	Plataforma para crear aplicaciones y agentes IA generativos (LLMOps). Enfoque en construcción de apps IA sin código.	Nativo para LLMs (OpenAI, Claude, Llama, Gemini, etc.) RAG integrado, memoria, agentes, herramientas Flujos de IA, prompts, evaluación y observabilidad	Baja a Media Equipos de producto, IA builders, analistas y desarrolladores.	Cloud (Dify Cloud) o Self-hosted (Open Source). Diseñado para escalar apps y agentes IA.	Open Source: Gratis (Self-hosted) Cloud: desde US$59/mes (Starter) Planes empresariales disponibles.

Resumen rápido

n8n: máximo control y flexibilidad (self-hosted).

Zapier: la forma más fácil y rápida (no-code).

Make: potencia visual con gran escalabilidad.

Pipedream: ideal para desarrolladores y APIs.

Dify: construye apps y agentes IA generativos de punta a punta.

TRABAJO PRÁCTICO EN CLASE – ORQUESTACIÓN CON LLMs (DIFY)

OBJETIVO

Diseñar e implementar una aplicación simple en Dify que integre un modelo de lenguaje (LLM) con una base de conocimiento (RAG) y lógica de workflow.

RECURSOS DISPONIBLES

1. BASE DE CONOCIMIENTO NOTEBOOK LM

https://notebooklm.google.com/notebook/fa54a54b-b614-4e6f-a1d0-34dc6822cb1e

2. PLATAFORMA DE DESARROLLO

Dify
(crear cuenta previamente)

DURACIÓN
1 hora 15 minutos

MODALIDAD
Grupos de 2 o 3 personas

PLATAFORMA
Dify
(crear cuenta previamente)

CONSIGNA

Cada grupo deberá construir en Dify un asistente que responda preguntas utilizando documentos o páginas web públicas como contexto (RAG).

Recibir pregunta del usuario → Recuperar información relevante desde una base de conocimiento → Generar respuesta breve y clara → Evitar inventar información cuando el contexto no sea suficiente

PASO A PASO SUGERIDO

1. Ingresar a Dify.
2. Crear una nueva aplicación.
3. Crear una base de conocimiento.
4. Cargar como contexto al menos una de estas opciones:
   - Archivos provistos por la cátedra
   - Páginas públicas de documentación
   - Wikipedia u otras fuentes abiertas
5. Configurar el modelo LLM.
6. Definir un prompt claro para que el asistente:
   - ✓ Responda solo con base en el contexto
   - ✓ Sea breve y preciso
   - ✓ Avise cuando no encuentre información suficiente
7. Probar al menos 3 preguntas.
8. Ajustar el prompt o la base si la respuesta no funciona bien.
9. Publicar la aplicación.
10. Entregar el link público.

REQUISITOS MÍNIMOS

1. Uso de un modelo LLM
2. Un prompt bien definido (con instrucciones claras)
3. Uso de contexto (knowledge base) o lógica de workflow
4. Al menos un ejemplo funcional probado

ENTREGABLE

Cada grupo deberá entregar:

Link público de la aplicación en Dify

IMPORTANTE

El objetivo es demostrar comprensión de:

- Orquestación de LLMs
- Uso de prompts
- Integración con contexto (RAG) o workflows

No es necesario construir algo complejo, sino correcto y funcional.

IDEA CLAVE

Integrar LLMs + contexto (RAG) + lógica de workflow para crear asistentes inteligentes útiles y confiables.

ÉXITO DEL TRABAJO

Correcto, funcional y bien orquestado.